

Pronóstico de series de tiempo (forecasting)

Sesión 2

Docente: Luis Garayar



Acuerdos para la sesión:

- **Puntualidad**

Se requiere puntualidad para un mejor desarrollo del curso.

- **Celulares en silencio**

Es necesario que los celulares permanezcan en silencio durante la clase para no interrumpir la sesión.

- **Preguntas y consultas**

Las preguntas pueden realizarse en cualquier momento. Las consultas muy particulares se revisarán al final de la clase.

- **Cumplimiento de tareas**

Realizar las actividades y/o tareas encomendadas dentro de los plazos establecidos.




Contenido

- Elección y definición del horizonte temporal
- Validación de resultados
- Enfoque de Alisados o Suavizados: Simple, Doble y Holt-Winters
- Bondad de Ajuste de un modelo de serie de tiempo

ELECCIÓN Y DEFINICIÓN DEL HORIZONTE TEMPORAL


- Identificación de las características que debe tener la data para el proceso de modelización, de acuerdo a lo que se necesita solucionar en el negocio.
- Se debe identificar las fuentes de información disponible con las que contamos y contaremos en el futuro para que la obtención de los datos sea siempre factible.



VALIDACIÓN DE RESULTADOS


Validación Out of Sample (OOS)

Una vez seleccionada la muestra para la elaboración del modelo, se divide aleatoriamente ésta en 2 sub muestras, una para el entrenamiento del modelo y la otra para su validación. Generalmente la muestra de validación está entre el 10% y 25% del total.




Validación Out of time (OOT)


Se elige una muestra o más muestras fuera del horizonte temporal que se usó en el entrenamiento del modelo




VALIDACIÓN DE RESULTADOS




Enfoque de los Alisados o Suavizados





Introducción

Los métodos de pronóstico de suavizado se pueden considerar como filtros que toman entradas y separan los componentes de tendencia y ruido, como se muestra en la siguiente figura:



Enfoques de los suavizados

Este enfoque, conceptualmente, está cerca del enfoque de promedio móvil ya que ambos se basan en pronosticar los valores futuros de la serie promediando las observaciones pasadas de la serie.

La principal distinción entre los enfoques de suavizado exponencial y el promedio móvil es que el primero promedia todas las observaciones en serie, a diferencia de un subconjunto de m observaciones de este último.



Suavización
exponencial Simple

Suavización
exponencial Doble

Suavización
exponencial de
orden superior

Modelo de Holt

**Modelo de Holt-
Winters**

Suavizado Exponencial Simple (SES)

Es el modelo de pronóstico más simple entre la familia de suavizado exponencial.

La suposición principal de este modelo es que la serie se mantiene en el mismo nivel (es decir, la media local de la serie es constante) a lo largo del tiempo y, por lo tanto, este modelo es adecuado para series sin componentes de tendencia ni estacionales.

Además, la función SES es una función escalonada, dónde el valor pronosticado n del modelo se convierte en la entrada del próximo pronóstico de las siguientes $n + 1$ observaciones. Usamos la siguiente ecuación:

$$Y_{T+n}^{\hat{}} = Y_{T+1}^{\hat{}} = \alpha Y_T + (1 - \alpha) Y_T^{\hat{}}$$

$Y_{T+n}^{\hat{}}$ es el valor pronosticado de la observación $T + 1$ para una serie con n observaciones (por ejemplo, $T = 1, \dots, n$)


Y_T es la observación T de la serie.

α es el parámetro de suavizado del modelo, donde $0 < \alpha \leq 1$

$Y_T^{\hat{}}$ es el valor pronosticado de la observación T en el paso $T-1$

Suavizado Exponencial Simple (SES)

Mes	Valor	Pronóstico
ene-18	1,990	
feb-18	1,921	
mar-18	1,891	
abr-18	1,797	
may-18	1,825	
jun-18	1,802	
jul-18	1,748	
ago-18	1,647	
sep-18	1,632	
oct-18	1,667	
nov-18	1,768	
dic-18	1,850	
ene-19	1,895	1,795
feb-19	2,002	1,779
mar-19	2,024	1,767
abr-19	2,136	1,756
may-19	2,285	1,753
jun-19	2,287	1,747



Suavizado Exponencial Doble (Holt)

El método Holt, también conocido como el modelo de suavizado exponencial doble, es una versión ampliada del modelo SES.

Se basa en la estimación del nivel y la tendencia más recientes con el uso de dos parámetros de suavizado, α y β .

Una vez que el modelo estima el nivel y la tendencia más recientes (**LT** y **TT** , respectivamente), los utiliza para construir el pronóstico de la serie utilizando la siguiente ecuación:

- Para un modelo de serie aditivo

$$\hat{Y}_{T+h} = L_T + hT_T$$

- Para un modelo de serie multiplicativo

$$\hat{Y}_{T+h} = L_T \times hT_T$$


$YT+h$ es el valor pronosticado de una serie con T observaciones.

LT es la estimación del nivel de serie en el tiempo T.

TT es la estimación de la tendencia en el tiempo T.

h es el número de pasos de pronóstico desde el tiempo T.

Suavizado Exponencial Doble (Holt)



Suavizado Exponencial Holt-Winters

El modelo Holt-Winters (HW) es una versión extendida del modelo Holt y puede manejar datos de series temporales con componentes de tendencia y estacionales.

Pronosticar el componente estacional requiere un tercer parámetro y ecuación más suaves, además de los del nivel y la tendencia.

Tanto la tendencia como los componentes estacionales podrían tener una estructura aditiva o de multiplicidad, lo que agrega cierta complejidad al modelo ya que existen múltiples combinaciones posibles

- **Modelo aditivo**

$$\hat{Y}_{T+1} = L_T + hT_T + S_{T+h-m}$$

$$L_T = \alpha(Y_T - S_{T-m}) + (1 - \alpha)(L_{T-1} + T_{T-1})$$

$$T_T = \beta(L_T - L_{T-1}) + (1 - \beta) + (1 - \beta)T_{T-1}$$

$$S_T = \gamma(Y_T - L_T) + (1 - \gamma)S_{T-m}$$

- **Modelo multiplicativo**


$$\hat{Y}_{T+1} = (L_T + kT_T)S_{T+k-m}$$

$$L_T = \frac{\alpha Y_T}{S_{T-m}} + (1 - \alpha)(L_{T-1} + T_{T-1})$$

$$T_T = \beta(L_T - LT - 1) + (1 - \beta)T_{T-1}$$


$$S_T = \gamma \frac{Y_T}{L_T} + (1 - \gamma)S_{T-m}$$

Suavizado Exponencial Holt-Winters



Bondad de Ajuste del Modelo

AR



Bondad de ajuste del modelo y de los residuos

RSME: Error cuadrático medio, mide la cantidad de error que hay entre dos conjuntos de datos. En otras palabras, compara un valor predicho y un valor observado o conocido.

$$RMSE = \sqrt{\frac{1}{n} \sum_{i=1}^n (y_i - \hat{y}_i)^2}$$

y_i : valores reales
 $\hat{y}_i$: valores predichos




Criterio de información de Akaike (AIC) es una medida nos proporciona un medio para la selección del modelo. AIC maneja un trade-off entre la bondad de ajuste del modelo y la complejidad del modelo. Se basa en la entropía de información: se ofrece una estimación relativa de la información perdida cuando se utiliza un modelo determinado.

$$AIC = 2k - 2\ln(L) \quad k = P + Q + p + q + 1 \text{ — number of parameters in the model}$$

El uso del puntaje AIC como criterio de selección de modelo no garantiza que el modelo seleccionado no viole los supuestos del modelo seleccionado. Por lo tanto, el siguiente paso es aplicar un análisis residual para verificar que los residuos tengan las siguientes características:

- La media y la varianza son constantes.
- Ruido blanco o no correlacionado.
- Normalmente distribuido

Bondad de ajuste del modelo y de los residuos








Contenido

- Gráficas de ACF y PACF
- Enfoque de Box-Jenkins: AR, MA, ARMA, ARIMA, ARIMA estacional
- Identificación de los parámetros del modelo ARIMA

Enfoque de Box-Jenkins




Gráficas típicas de ACF y PACF


MODELO	Función de autocorrelación simple (FAS)	Función de autocorrelación parcial (FAP)
Autorregresivo (AR)		
De media móvil (MA)		
ARMA		
ARIMA		

Gráficas típicas de ACF y PACF


Nivel no constante (tendencia)



Varianza no constante




Nivel y varianza no constantes




Gráficas típicas de ACF y PACF

Serie estacionaria



Serie estacionaria






Ruido blanco

Una de las principales suposiciones de la familia de modelos ARIMA es que la serie de entrada es un proceso estacionario. Esta suposición se basa en el teorema de representación de Wold, que establece que cualquier proceso estacionario puede representarse como una combinación lineal de ruido blanco.

El ruido blanco o sonido blanco es una señal aleatoria (proceso estocástico) que se caracteriza por el hecho de que sus valores de señal en dos tiempos diferentes no guardan correlación estadística

Se espera que los residuales o componente aleatoria de una serie de tiempo tenga comportamiento de ruido blanco para decir que la serie es estacionaria.



Proceso AR

El proceso AR define el valor actual de la serie, Y_t , como una combinación lineal de los p rezagos anteriores de la serie, y se puede formalizar con la siguiente ecuación:

$$AR(p) : Y_t = c + \sum_{i=1}^p \phi_i Y_{t-i} + \epsilon_t$$

AR (p): es la notación para un proceso AR con orden p

c : representa una constante p : define el número de retrasos contra Y_t


Φ_i : es el coeficiente del retraso de la serie (aquí Φ_1 debe estar entre -1 y 1, de lo contrario, la serie tendría una tendencia ascendente o descendente y, por lo tanto, no puede ser estacionaria con el tiempo).

Y_{t-i} : es el retraso de la serie.


ϵ_t : Representa el término de error, que es ruido blanco.

$$AR(1) : Y_t = c + \phi_1 Y_{t-1} + \epsilon_t$$


$$AR(2) : Y_t = c + \phi_1 Y_{t-1} + \phi_2 Y_{t-2} + \epsilon_t$$



Proceso AR



Proceso AR



Proceso MA

El objetivo del proceso de promedio móvil es capturar patrones en los residuos, si existen, modelando la relación entre Y_t , el término de error, ϵ_t y los términos de error pasados de los modelos (por ejemplo, $\epsilon_{t-1}, \epsilon_{t-2}, \dots, \epsilon_{t-q}$). La estructura del proceso de MA es bastante similar a la del AR.

$$MA(q) : Y_t = \mu + \epsilon_t + \sum_{i=1}^q \theta_i \epsilon_{t-i}$$

MA(q): es la notación para un proceso de MA con orden q


μ : representa la media de la serie. $\epsilon_{t-1}, \epsilon_{t-2}, \dots,$

ϵ_{t-q} : son términos de error de ruido blanco.


θ_i : es el coeficiente correspondiente de ϵ_{t-i}

q : define el número de términos de error pasados que se utilizarán en la ecuación.


A diferencia de los procesos AR (1), los modelos MA (1) no exhiben un comportamiento radicalmente diferente al cambiar θ



Proceso MA



Proceso MA



Proceso ARIMA

En algunos casos, combinar los dos nos permite manejar datos de series de tiempo más complejas. El modelo ARMA es una combinación de los procesos AR (p) y MA (q) y se puede escribir de la siguiente manera:

$$ARMA(p, q) : Y_t = c + \sum_{i=1}^p \phi_i Y_{t-i} + \sum_{i=1}^q \theta_i \epsilon_{t-i} + \epsilon_t$$

Una de las limitaciones de los modelos AR, MA y ARMA es que no pueden manejar datos de series temporales no estacionarias. Por lo tanto, si la serie de entrada no es estacionaria, se requiere un paso de pre-procesamiento para transformar la serie de un estado no estacionario a un estado estacionario.

El modelo ARIMA proporciona una solución para este problema al agregar el proceso integrado al modelo ARMA. El proceso Integrado (I) es simplemente diferenciar la serie con sus retrasos, donde el grado de diferenciación está representado por el parámetro d. El proceso de diferenciación, como vimos anteriormente, es una de las formas en que puede transformar una serie de no estacionario a estacionario.

Y_d es la diferencia d de la serie. Agreguemos el componente de diferenciación al modelo ARMA y formalicemos el modelo ARIMA:

$$ARIMA(p, d, q) : Y_d = c + \sum_{i=1}^p \phi_i Y_{d-i} + \sum_{i=1}^q \theta_i \epsilon_{t-i} + \epsilon_t$$

Proceso ARIMA

Como puede ver, los modelos AR y MA se pueden representar con el modelo ARMA, también puede representar los modelos AR, MA o ARMA con el modelo ARIMA, por ejemplo:

- El modelo ARIMA (0, 0, 0) es equivalente al ruido blanco.
- El modelo ARIMA (0, 1, 0) es equivalente a un camino aleatorio.
- El modelo ARIMA (1, 0, 0) es equivalente a un proceso AR (1)
- El modelo ARIMA (0, 0, 1) es equivalente a un proceso MA (1)
- El modelo ARIMA (1, 0, 1) es equivalente a un proceso ARMA (1,1)

Modelo Estacional ARIMA

Un modelo estacional ARIMA se forma al incluir términos estacionales adicionales en los modelos ARIMA que hemos visto hasta ahora. Está escrito de la siguiente manera:

ARIMA

(p, d, q)

↑
**Parte no
estacional del
modelo**

$(P, D, Q)_m$

↑
**Parte estacional de
del modelo**

Proceso ARIMA

Las series con tendencia secular y variaciones cíclicas pueden representarse mediante los modelos **ARIMA(p, d, q)(P, D, Q)**. El primer paréntesis **(p, d, q)** se refiere a la **tendencia secular o parte regular** de la serie y el segundo paréntesis **(P, D, Q)** se refiere a las **variaciones estacionales, o parte cíclica** de la serie temporal.

En este sentido, se adjuntan algunas expresiones del modelo:

- **ARIMA(0, 1, 1)(0,0,1)₁₂:** $(1 - B) X_t = (1 - v_1 B^{12}) (1 - \delta_{12} B^{12})$
- **ARIMA(0, 1, 1)(0,1,1)₁₂:** $(1 - B) (1 - B^{12}) X_t = (1 - v_1 B^{12}) (1 - \delta_{12} B^{12})$
- **ARIMA(2, 1, 0)(1,0,0)₁₂:** $(1 - \phi_1 B - \phi_2 B^{12}) (1 - \Omega_1 B^{12}) (1 - B) X_t = a_t$
- **ARIMA(1, 1, 1)(2,1,1)₁₂:** $(1 - \phi_1 B) (1 - \Omega_1 B^{12} - \Omega_2 B^{24}) (1 - B^{12}) (1 - B) X_t = (1 - v_1 B) (1 - \delta_{12} B^{12}) a_t$

Por ejemplo, un modelo ARIMA (1,1,1) (1,1,1) 4 (sin una constante) es para datos cuatrimestrales (m = 4) puede escribirse como:

$$(1 - \phi_1 B) (1 - \Phi_1 B^4) (1 - B) (1 - B^4) y_t = (1 + \theta_1 B) (1 + \Theta_1 B^4) \varepsilon_t.$$

Identificación inicial de parámetros ARIMA


Identificar un modelo significa utilizar los datos recogidos, así como cualquier información de cómo se general la serie temporal objeto de estudio, para sugerir un conjunto reducido de posibles modelos, que tengan muchas posibilidades de ajustarse a los datos. Ante una serie temporal empírica, se deben encontrar los valores **(p, d, q)** más apropiados.

- Si la serie temporal presenta una tendencia, lo primero que debe de hacerse es convertirla en estacionaria mediante una diferenciación de orden **d**. Una vez diferenciada la serie, una buena estrategia consiste en comparar los correlogramas de la función de autocorrelación (ACF) y la función de autocorrelación parcial (ACFP), proceso que suele ofrecer una orientación para la formulación del modelo orientativo.
- ♣ Los procesos autorregresivos presentan función de autocorrelación parcial (ACFP) con un número finito de valores distinto de cero. *Un proceso **AR(p)** tiene los primeros p términos de la función de autocorrelación parcial distintos de cero y los demás son nulos.*
Esta afirmación es muy fuerte, y en la práctica se considera que una muestra dada proviene de un proceso autorregresivo de orden **p** si los términos de la función de autocorrelación parcial son casi cero a partir del que ocupa el lugar **p**.
- ♣ Los procesos de medias móviles presentan función de autocorrelación con un número finito de valores distintos de cero. *Un proceso **MA(q)** tiene los primeros q términos de la función de autocorrelación distintos de cero y los demás son nulos.*


Identificación inicial de parámetros ARIMA

Proceso	Función de autocorrelación (ACF)	Función de autocorrelación parcial (ACFP)
MA(q)	Solo los q primeros coeficientes son significativos. El resto se anulan bruscamente (coef. 0 para retardo >q)	Decrecimiento rápido exponencial atenuado u ondas sinusoidales.
AR(p)	Decrecimiento rápido exponencial atenuado u ondas sinusoidales.	Solo los p primeros coeficientes son significativos. El resto se anulan bruscamente (coef. 0 para retardo >q)
ARIMA(p, d, q)	Comportamiento irregular en los retardos (1, ... , q) con q picos. Decrecimiento para retardos posteriores a q .	Decrece (aproximadamente con exponenciales atenuados y ondas sinusoidales). No cero pronto.

Identificación inicial de parámetros ARIMA




ARMA(2,1)




ARMA(3,3)

Identificación inicial de parámetros ARIMA

Serie original (tendencia)




Serie diferenciada (estacionaria)




ARIMA(0,1,0)

Identificación inicial de parámetros ARIMA

Serie original (tendencia)




Serie diferenciada (estacionaria)




ARIMA(3,1,2)

Identificación inicial de parámetros ARIMA




ARIMA(1,0,1)(1,0,3)7




ARIMA(1,0,1)(1,0,2)12

Identificación inicial de parámetros ARIMA




ARIMA(1,1,1)(0,1,1)12




ARIMA(0,1,2)(0,1,1)12

Ejemplo de identificación de parámetros




$q = 3$



$p = 3$

ARIMA (3, 0, 3)

Ejemplo de identificación de parámetros



$Q = 1$

$m = 4$

$P = 1$

ARIMA (1, 1, 1)(1, 1, 1) 4

Auto ARIMA

pmdarima 1.6.1

```
pip install pmdarima
```

[Latest version](#)

Released: May 19, 2020

Python's forecast::auto.arima equivalent

Navigation

Project description

Release history

Download files

Project description

pmdarima

pypi package 1.6.1 **PASSED** **Mac and Windows Builds** passing **codecov** 97% **python** 3.5+ **downloads** 3.5M
downloads/week 91k

Pmdarima (originally `pyramid-arima`, for the anagram of 'py' + 'arima') is a statistical library designed to fill the void in Python's time series analysis capabilities. This includes:



¡GRACIAS!

